


Klinik Veri Rehabilitasyon Hattı

Clinical Data Rehabilitation Pipeline



AMAÇ

Inter

Talent_Academy_Case_DT_2025.xlsx dosyasındaki ham klinik veriyi; temizleme, onarma ve güçlendirme süreçlerinden geçirerek makine öğrenmesi modelleri için kusursuz hale getirmek.

YAKLAŞIM

Inter

Tek dosya mimarisi (pipeline.py) ve modüler kural setleri (rules/) ile ölçeklenebilir bir veri iyileştirme süreci.

Teşhis: Veri Sağlığı ve Semptomlar

Ham verinin “ağrılı” noktaları ve müdahale gereksinimleri.

TREATMENT GOAL

HEDEF: Bu 'hasta' veriyi taburcu etmeden önce total NA sayısını 0'a indirmek ve tüm özellikleri sayısal formata (Encoding/Scaling) dönüştürmek.

PATIENT STATUS



Tutarsız Metin Girişleri: Büyük/küçük harf karmaşası, yazım hataları.

Örn: OMUZUN DARBE SENDROMU vs Omuz Darbe Send.



Doku Kaybı (Eksik Veriler): Kritik alanlarda (Yaş, Kan Grubu, Tedavi Süresi) bulunan NaN değerler.




Düzensiz Formatlar: Sayısal olması gereken sürelerin metin olarak girilmesi.

Örn: "15 Seans", "20 dk"



Gürültü (Noise): Analiz değeri taşımayan ifadeler.

Örn: GENEL, DİĞER, HATA



Tedavi Planı: Bütüncül İyileştirme Süreci

Ham veriden modele hazır yapıya geçiş adımları.



FAZ 1 - HAZIRLIK & CERRAHİ (PREPARATION)

Talent_Academy_
Case_DT_2025.xlsx

- Keşif & Raporlama (head, info)
- Metinsel sürelerin sayısala çevrilmesi
- Düşük kardinaliteli kolonların category tipine dönüşümü



FAZ 2 - MÜDAHALE (INTERVENTION)

- Kural tabanlı metin normalizasyonu (rules/*.py)
- Uygulama yerlerinin üst gruplara map edilmesi
- **KNN Imputation:** Eksik dokuların onarımı



FAZ 3 - GÜÇLENDİRME (STRENGTHENING)

- Özellik Türetimi (Feature Engineering)
- Yaş verisinin ölçeklenmesi (Scaling)
- One-Hot & Multi-Hot Encoding

model_ready.xlsx

Faz 1: Cerrahi Temizlik ve Normalizasyon

rules/ klasörü altındaki uzman reçetelerle metin iyileştirme.

METİN DETOKSU & GÜRÜLTÜ ATIMI


- noise.py modülü ile 'TEDAVİ', 'SEANS' gibi gereksiz kelimelerin temizlenmesi.
- Kanonikleştirme: tanilar.py, alerji.py gibi dosyalardaki Regex kuralları.

HAM GİRDİ (Pathology)	İŞLEM (Surgery)	İŞLENMİŞ ÇIKTI (Health)
OMUZUN DARBE SENDROMU	`Regex Substitution`	**OMUZ DARBE SENDROMU**
TOZ ALERJİSİ	`Normalization`	**TOZ ALERJİSİ**
HTN	`Canonical Mapping`	**HİPERTANSİYON**

Not: Sistem, metinleri önce BÜYÜK HARF formatına çeker, ardından regex desenlerini uygular.

Faz 2: Eksik Dokuların Onarımı (KNN Imputation)

Boşlukları tahminle değil, komşuluk ilişkisiyle (Nearest Neighbors) dolduruyoruz.



TEKNİK PROSEDÜR

- **Matris Kapsamı:** İmputasyon matrisine Yaş, Tedavi Süreleri, Kan Grubu, Cinsiyet, Uyruk ve Bölüm dahil edilir.
- **Algoritma:** 'KNNImputer' (n_neighbors=5, weights='distance')
- **Kategorik Stratejisi:** Kategorik veriler işlem öncesi geçici kodlara çevrilir, imputasyon sonrası tekrar etikete döndürülür.
- **Güvenlik:** KNN işlemi sonrası NA kalırsa sistem hata fırlatır.


Not: Kan grubu verisindeki '0 Rh+' gibi boşluk hataları imputasyon öncesi temizlenir.

Faz 3: Güçlendirme ve Egzersiz (Feature Engineering)

Veriyi algoritmaların anlayacağı 'dile' çevirmek.


ENCODING (KODLAMA)

- **One-Hot Encoding:** Cinsiyet, Kan Grubu, Uyruk (`drop\_first=True`)
- **Multi-Hot Encoding:** Çok etiketli alanlar (Tanılar, Alerjiler) için Top-N yaklaşımı.
 - En sık görülen 30 Tanı sütunlaşır.
- **Other Sütunu:** Top-N dışında kalan nadir veriler `\_\_other` sütununda toplanır.



SCALING (ÖLÇEKLEME)

- **Yaş Değişkeni:** KNN işleminden *sonra* `StandardScaler` ile ölçeklenir.



İZLENEBİLİRLİK


- **Türetilmiş Metrikler:** `HastaTedaviID` ve `HastaTedaviSeansID` kimlikleri oluşturulur.

Görsel Kontrol ve Raporlama (Monitoring)

reports/figures/ klasörüne otomatik üretilen sağlık karnesi.


Otomatik EDA Raporu

Dağılımlar




YAŞ DAĞILIMI

İlişkiler



KORELASYON MATRİSİ
(Seaborn)

Kategorik



UYRUK / CİNSİYET

- **Grafik Listesi:** Yaş Histogramı, Tedavi Süresi (Seans/Dakika), Korelasyon Isı Haritası.
- **Görsel Standart:** Tüm grafik etiketleri otomatik olarak BÜYÜK HARF standardına ('UC() fonksiyonu) getirilir.

Tissue Coral

PRIVACY FIRST: Grafikte 'HastaNo' veya 'HastaTedaviID' gibi kişisel veriler asla görselleştirilmez.

Taburcu İşlemleri: Nihai Çıktılar

Analiz ve modelleme için 3 farklı formatta teslimat.



data/rows.xlsx

Temizlenmiş, satır bazlı ham veri (İzlenebilirlik için).



data/by_treatment.xlsx

Tedavi bazında özetlenmiş metrikler.



**ALTIN
STANDART**

data/model_ready.xlsx


- Eksiksiz (Total NA: 0)
- Ölçeklenmiş (Scaled)
- Encoded (One-Hot / Multi-Hot)

Klinik Mimarisi ve Teknoloji

Sağlam, genişletilebilir ve modüler altyapı.



Tüm operasyonu yöneten tek merkez.



Genişletilebilir kural kütüphanesi.

 **Python**
3.12.6

 **Pandas**
(Veri Manipülasyonu)

 **Scikit-learn**
(Imputation/Scaling)

 **Seaborn**
(Görselleştirme)

Otomasyon: requirements.txt
ile tek komutla kurulum.

Sonuç: Veri Kalitesini Şansa Bırakmıyoruz

Bu proje, standart bir veri temizliğinin ötesine geçerek; ham klinik kayıtları disiplinli bir “rehabilitasyon” sürecinden geçirmiştir. Eksik veriler bilimsel yöntemlerle tamamlanmış, metinler standartlaştırılmış ve makine öğrenmesi modellerinin en yüksek performansı göstermesi için gerekli zemin hazırlanmıştır.



Projeyi GitHub'da İnceleyin:
[EdaCelikeloglu/Physical_Therapy_Data_Analysis_Project](https://github.com/EdaCelikeloglu/Physical_Therapy_Data_Analysis_Project)